


# Redes Neurais Artificiais



links uteis:

- <https://array-3d-viz.vercel.app/>
- <https://arrayvis.netlify.app/>

---

## O que são redes neurais?

As redes neurais são um tipo de modelo computacional inspirado no funcionamento do cérebro humano, especificamente na forma como os neurônios se conectam e processam informações. Elas são uma das técnicas mais poderosas e populares no campo do machine learning (aprendizado de máquina) e são usadas para resolver uma ampla variedade de problemas, como reconhecimento de imagens, processamento de linguagem natural, previsão de séries temporais e muito mais.

## Inspiração biológica

As redes neurais são inspiradas no sistema nervoso humano:

- **Neurônios biológicos:** No cérebro, os neurônios são células que processam e transmitem informações por meio de conexões chamadas *sinapses*.
- **Neurônios artificiais:** Em redes neurais, os neurônios artificiais (também chamados de unidades ou nós) são modelos matemáticos que simulam o comportamento dos neurônios biológicos.

## Estrutura de uma rede neural artificial

Uma rede neural é composta por camadas de neurônios artificiais interconectados. Essas camadas são organizadas da seguinte forma:

### 1. Camada de entrada (Input Layer):

- Recebe os dados de entrada (por exemplo: pixels de uma imagem ou palavras de um texto)
- Cada neurônio na camada de entrada representa uma característica (*feature*) dos dados

### 2. Camadas Ocultas (Hidden Layers):

- São camadas intermediárias entre a entrada e a saída
- Cada neurônio em uma camada oculta processa as entradas recebidas e passa o resultado para a próxima camada

### 3. Camada de Saída (Output Layers):

- Produz o resultado final da rede (por exemplo, a classe de uma imagem ou o valor de uma previsão)
- O número de neurônios na camada de saída depende do problema (por exemplo, 1 neurônio para regressão ou vários neurônios para classificação)

## Funcionamento

### 1. Propagação (Feed Forward):

- Os dados de entrada são passados pela rede, camada por camada
- Cada neurônio calcula uma soma ponderada das entradas, aplica uma *função de ativação* e passa o resultado adiante

### 2. Função de Ativação:

- Introduce não-linearidade na rede, permitindo que ela aprenda padrões complexos
- Exemplos comuns: ReLU, sigmoide, tanh

### 3. Cálculo da Perda (Loss):

- A saída da rede é comparada com o valor real (rótulo) para calcular o erro (ou perda)

#### 4. Retropropagação (Backpropagation):

- O erro é propagado de volta pela rede, ajustando os pesos e vieses dos neurônios para minimizar a perda

#### 5. Atualização dos Pesos:

- Os pesos são ajustados usando algoritmos de otimização, como gradiente descendente (gradient descent)

## Tipos de redes neurais

#### 1. Redes Neurais Feedforward:

- A informação flui em uma única direção, da entrada para a saída.
- Usadas para problemas simples, como classificação e regressão.

#### 2. Redes Neurais Convolucionais (CNNs):

- Especializadas em processar dados com estrutura espacial, como imagens.
- Usam **filtros convolucionais** para extrair características.

#### 3. Redes Neurais Recorrentes (RNNs):

- Projetadas para trabalhar com sequências de dados, como texto ou séries temporais.
- Têm "memória" para processar informações ao longo do tempo.

#### 4. Redes Neurais de Memória de Longo Prazo (LSTMs):

- Uma variação das RNNs, capazes de aprender dependências de longo prazo.

#### 5. Redes Neurais Generativas (GANs):

- Compostas por duas redes (geradora e discriminadora) que competem entre si.
- Usadas para gerar dados novos, como imagens ou textos.

## Underfitting e Overfitting

### Overfitting (Sobreajuste)

O **overfitting** ocorre quando o modelo aprende demais os detalhes e ruídos dos dados de treinamento, a ponto de prejudicar seu desempenho em dados novos (não vistos).

#### Características do Overfitting:

- O modelo tem um desempenho excelente nos dados de treinamento, mas ruim nos dados de teste/validação.

- O modelo "decora" os dados de treinamento em vez de aprender padrões gerais.
- Geralmente acontece quando o modelo é muito complexo (muitos parâmetros) em relação à quantidade de dados disponíveis.

## Exemplo:

Imagine um modelo que tenta prever se uma fruta é uma maçã ou uma laranja. Se o modelo se ajustar demais aos dados de treinamento, ele pode começar a considerar características irrelevantes, como pequenas marcas ou manchas nas frutas, em vez de focar em características gerais como cor e formato.

## Como evitar o Overfitting:

- **Regularização:** Técnicas como L1/L2 regularization penalizam pesos muito grandes no modelo.
- **Dropout:** Desativa aleatoriamente neurônios durante o treinamento para evitar dependência excessiva em características específicas.
- **Aumento de Dados (Data Augmentation):** Gera novas versões dos dados de treinamento (por exemplo, rotacionar imagens) para aumentar a diversidade.
- **Validação Cruzada:** Avalia o desempenho do modelo em diferentes subconjuntos dos dados.
- **Redução da Complexidade do Modelo:** Usar menos camadas ou neurônios em redes neurais.
- **Early Stopping:** Interromper o treinamento quando o desempenho no conjunto de validação para de melhorar.

## Underfitting (Subajuste)

O **underfitting** ocorre quando o modelo é muito simples para capturar os padrões subjacentes nos dados, resultando em um desempenho ruim tanto nos dados de treinamento quanto nos dados de teste/validação.

## Características do Underfitting:

- O modelo tem desempenho ruim tanto nos dados de treinamento quanto nos dados de teste.
- O modelo não consegue aprender relações importantes nos dados.
- Geralmente acontece quando o modelo é muito simples (poucos parâmetros) ou o treinamento é insuficiente.

## Exemplo:

Usando o mesmo exemplo das frutas, um modelo subajustado pode não conseguir distinguir entre maçãs e laranjas porque não aprendeu características básicas como cor e

formato.

## Como evitar o Underfitting:

- **Aumentar a Complexidade do Modelo:** Adicionar mais camadas ou neurônios em redes neurais.
  - **Treinar por Mais Tempo:** Permitir que o modelo aprenda por mais épocas.
  - **Engenharia de Features:** Criar características mais relevantes para o modelo.
  - **Reduzir Regularização:** Diminuir a penalização sobre os pesos do modelo.
- 

## Pesos

Em uma rede neural, pesos são números que irão ser multiplicados pelos valores de entrada. Os pesos, basicamente, representam a importância relativa de cada entrada na rede neural.

Os pesos determinam como as entradas influenciam os valores de saída do modelo.

## Exemplo

Vamos imaginar que temos um modelo que prevê preços de uma casa em base:


$$x_1 \rightarrow \textit{Tamanho}$$

$$x_2 \rightarrow \textit{Quantidade de quartos}$$

se

$$w_1 = 100 \text{ e } w_2 = 50$$

isso significa que o tamanho da casa tem mais influência no preço dela do que a quantidade de quartos. Visualmente isso seria algo como:



É claro que ao treinar o modelo, ajustamos esses pesos com alguns outros algoritmos e equações.

## Bias (viés)


O viés é basicamente um valor que ajusta a saída sem depender da entrada. O viés ajuda o modelo a se ajustar melhor aos dados, especialmente quando as entradas são zero.

Na equação do perceptron:

$$z = x_1 * w_1 + x_2 * w_2 + x_3 * w_3 \cdots + b$$

ou

$$\sum_{i=1}^n (x_i * w_i) + b$$



No exemplo da previsão do preço da casa visto em **Pesos**, o viés pode representar um custo base (por exemplo, o valor do terreno) que não depende do tamanho da casa ou do número de quartos.

Assim como os pesos, o viés pode ser ajustado durante o treinamento do modelo para torná-lo mais preciso.

## Array shape (numpy)

O array shape ou "formato do array", por assim dizer, refere-se a forma ou estrutura do array, ou seja, às suas dimensões e ao tamanho em cada dimensão. O shape é a propriedade fundamental para entender e manipular arrays, especialmente em operações matemáticas e de machine learning.

## O que é um array shape?

- O shape descreve as dimensões de um array, ou seja, como os seus elementos são organizados
- É representado por uma tupla, onde cada valor indica o tamanho da dimensão correspondente
- Por exemplo, um array com o shape de (3, 4) tem 3 linhas e 4 colunas, ou seja, é uma lista com três listas dentro e cada lista tem quatro elementos:

```
# Shape(3, 4):  
arrayShape34 = [[0, 1, 2, 3],  
                [0, 1, 2, 3],  
                [0, 1, 2, 3]]
```

## Vetor


Um array de apenas uma dimensão (3, ), por exemplo, pode ser chamado de vetor:

```
import numpy as np  
arrayShape1D = np.array([0, 1, 2])  
  
print(arrayShape1D.shape) #(3,)
```

Visualmente, seria algo como:







## Matriz


Um array com duas dimensões sendo linha e coluna, `(2, 4)`, pode ser chamado de Matriz:

```
import numpy as np
arrayShape2D = np.array([0, 1, 2, 3],
                        [0, 1, 2, 3])

print(arrayShape2D.shape) #(2, 4)
```

Visualmente, seria algo como:





## Tensor


Um array com três dimensões sendo profundidade, linha e coluna `(2, 2, 2)`, pode ser chamado de Tensor:

```
import numpy as np
arrayShape3D = np.array([[[1, 2], [3, 4]], [[5, 6], [7, 8]]])

print(arrayShape3D.shape) #(2, 2, 2)
```

Visualmente, seria algo como:





Para arrays com dimensões superiores a três, o shape continua seguindo a mesma lógica, com um valor para cada dimensão.

```
import numpy as np
arr = np.random.rand(2, 3, 4, 5) # Array 4D

print(arr.shape) # (2, 3, 4, 5)
```

```
[[[ [0.39810981 0.76407385 0.12987125 0.10151332 0.13065959]
      [0.31533386 0.52475099 0.85915183 0.86389658 0.97788708]
      [0.81842117 0.44603532 0.25529811 0.56303873 0.82661583]
      [0.05714793 0.66767314 0.31084994 0.01936542 0.55144244]]

  [ [0.31277805 0.81486213 0.2677634 0.09741848 0.35765971]
      [0.37247493 0.84303157 0.5528428 0.93307044 0.38364596]
      [0.7121754 0.06851401 0.6238352 0.95527147 0.96056542]
      [0.10846951 0.74046929 0.16229514 0.33003873 0.53374489]]


  [ [0.53000064 0.9567412 0.94228628 0.82740308 0.76984276]
```

```
[0.72762549 0.45190647 0.79002725 0.28449173 0.97253081]
[0.72762549 0.45190647 0.79002725 0.28449173 0.97253081]
[0.72762549 0.45190647 0.79002725 0.28449173 0.97253081]
[0.17402416 0.73285112 0.83148087 0.4807747 0.1607782 ]
[0.05452911 0.84108166 0.11792574 0.987726 0.57350771]]]
```

```
[[[0.95608547 0.50674675 0.11108763 0.69770857 0.51779796]
[0.78666863 0.47308812 0.14633893 0.40425404 0.99609254]
[0.4118319 0.14335103 0.8373616 0.97377864 0.94555928]
[0.95041482 0.86502827 0.62761595 0.78588766 0.07112352]]]
```

```
[[0.40110238 0.10832828 0.97557906 0.2241916 0.6734595 ]
[0.04905729 0.78315032 0.42664928 0.84362507 0.19614023]
[0.97255042 0.60368831 0.29016525 0.51675281 0.42406429]
[0.90356054 0.40215171 0.28409738 0.65785291 0.28948903]]]
```

```
[[0.52720981 0.81876573 0.61579305 0.26600347 0.95322732]
[0.38618895 0.52702102 0.33616011 0.74055057 0.18387451]
[0.53713797 0.39526336 0.90730682 0.73095552 0.54927923]
[0.34964116 0.41478751 0.679752 0.89329891 0.70984594]]]]]
```



**Produto escalar (dot product)**

# Dot Product

$$\begin{bmatrix} a & b \end{bmatrix} \cdot \begin{bmatrix} x \\ y \end{bmatrix} = [ax + by]$$

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix} \cdot \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} ax + by \\ cx + dy \end{bmatrix}$$

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix} \cdot \begin{bmatrix} w & x \\ y & z \end{bmatrix} = \begin{bmatrix} aw + bx & ax + bz \\ cw + dx & cx + dz \end{bmatrix}$$

O produto escalar de dois arrays nada mais é do que a soma do produto dos elementos que ocupam a mesma posição nos dois arrays.

## Exemplo:

```
import numpy as np
arr_1 = np.array([1, 2, 3])
arr_2 = np.array([3, 2, 1])

print(np.dot(arr_1, arr_2)) # 10
```

$$\sum_{i=1}^n a_i * b_i$$

$$(1 * 3) + (2 * 2) + (3 * 1) = 3 + 4 + 3 = 10$$

Porém devemos tomar cuidado ao realizar o produto escalar de dois arrays com dimensões opostas, por exemplo, vamos pensar que eu tenha um `arr_1` como shape (4, ) e outro array `arr_2` com o shape (3, 4):

```
import numpy as np

arr_1 = np.array([1, 2, 3, 2.5])
```

```
arr_2 = np.array([[0.2, 0.8, -0.5, 1.0],  
                  [0.5, -0.91, 0.26, -0.5],  
                  [-0.26, -0.27, 0.17, 0.87]])
```

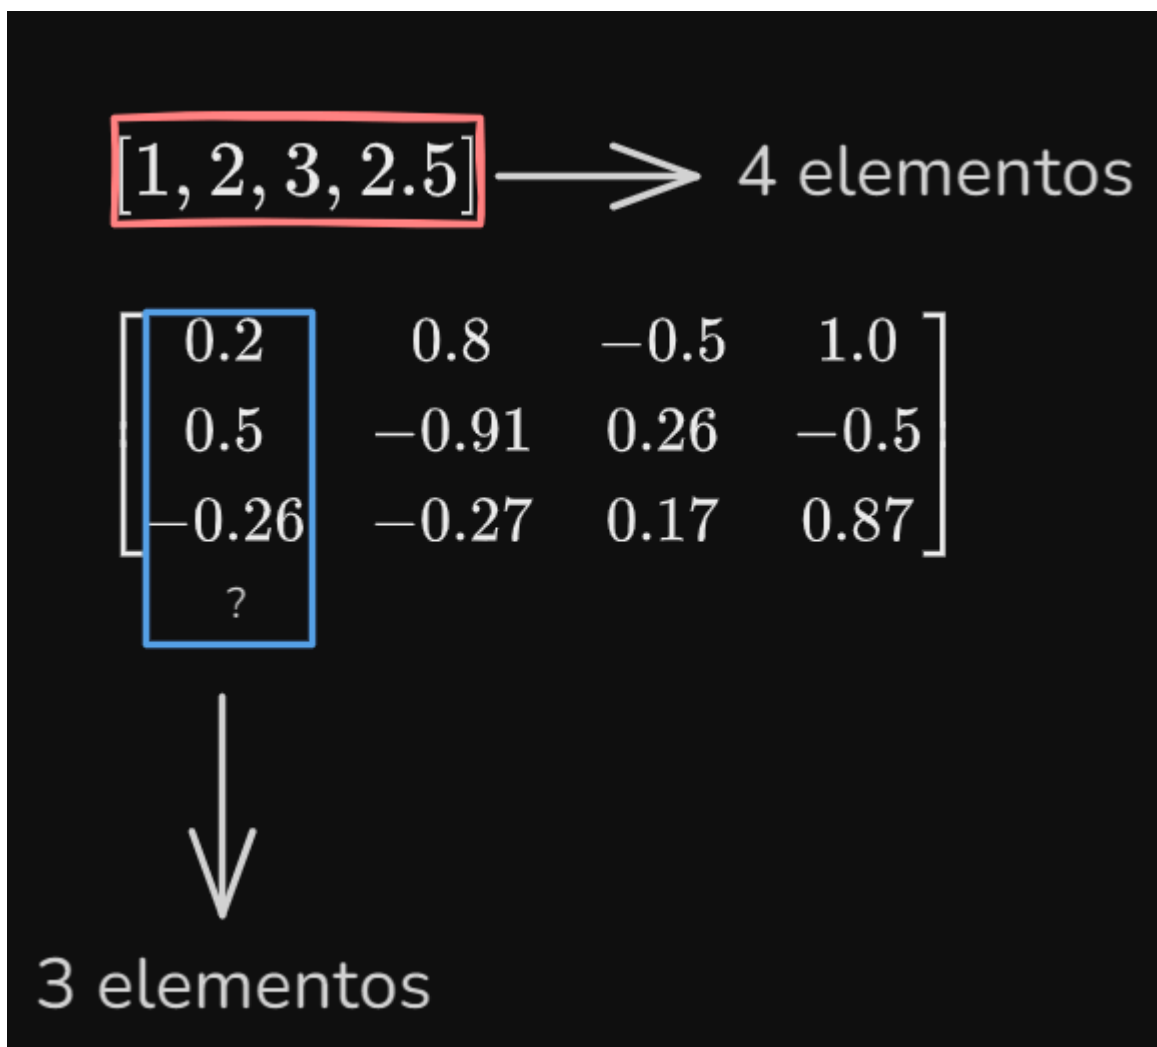
arr\_1:

[1, 2, 3, 2.5]

arr\_2:

$$\begin{bmatrix} 0.2 & 0.8 & -0.5 & 1.0 \\ 0.5 & -0.91 & 0.26 & -0.5 \\ -0.26 & -0.27 & 0.17 & 0.87 \end{bmatrix}$$

Aritmeticamente, esse cálculo não seria possível, mas por que? Bom, se você tentar calcular o produto escalar diretamente, teríamos que multiplicar cada elemento do `arr_1` com todos elementos da primeira coluna do `arr_2`, seria algo como:




$$1 * 0.2 + 2 * 0.5 + 3 * -0.26 + 2.5 * ?$$

e isso não seria possível, pelo menos não diretamente. Então como podemos resolver isso? Bom há duas maneiras, a primeira delas seria transpondo o segundo array, assim as colunas virariam linhas e as linhas se tornariam colunas ou vice-versa:

$$V = \begin{bmatrix} a \\ b \\ c \end{bmatrix} \rightarrow V^T = \begin{bmatrix} a & b & c \end{bmatrix}$$

OKPEDIA.ORG

Nesse caso o `arr_2` ficaria assim:



$$\begin{bmatrix} 0.2 & 0.5 & -0.26 \\ 0.8 & -0.91 & -0.27 \\ -0.5 & 0.26 & 0.17 \\ 1.0 & -0.5 & 0.87 \end{bmatrix}$$

```
import numpy as np

arr_2 = np.array([[0.2, 0.8, -0.5, 1.0],
                  [0.5, -0.91, 0.26, -0.5],
                  [-0.26, -0.27, 0.17, 0.87]])

arr_2 = arr_2.T # Transposição do array
```

Com essa transposição, teríamos a quantidade de linhas igual a quantidade de elementos no `arr_1`, obedecendo as regras do produto escalar e realizando a operação diretamente.

$$[1, 2, 3, 2.5] \begin{bmatrix} 0.2 & 0.5 & -0.26 \\ 0.8 & -0.91 & -0.27 \\ -0.5 & 0.26 & 0.17 \\ 1.0 & -0.5 & 0.87 \end{bmatrix} = (1 * 0.2) + (2 * 0.8) + (3 * (-0.5)) + \dots$$

Já a segunda maneira de fazermos isso seria invertendo a ordem dos arrays na operação, exemplo, vimos que se realizarmos a operação somando cada item do `arr_1` com cada linha da primeira coluna do `arr_2`:



$[1, 2, 3, 2.5] \rightarrow 4 \text{ elementos}$

0.2	0.8	-0.5	1.0
0.5	-0.91	0.26	-0.5
-0.26	-0.27	0.17	0.87
?			




3 elementos

Isso não seria possível por conta da quantidade de linhas a primeira coluna do `arr_2` tem, porém e se realizássemos a operação apenas invertendo os arrays? Por exemplo:


$$\begin{bmatrix} 0.2 & 0.8 & -0.5 & 1.0 \\ 0.5 & -0.91 & 0.26 & -0.5 \\ -0.26 & -0.27 & 0.17 & 0.87 \end{bmatrix} \begin{bmatrix} 1, 2, 3, 2.5 \end{bmatrix} = (0.2 * 1) + (0.8 * 2) + (-0.5 * 3) + \dots$$

Outra coisa que pode nos ajudar a pensar em que maneira devemos organizar os arrays para fazer esse produto escalar seria o seguinte:

Sabemos que, cada valor de entrada na nossa rede neural, precisa passar por alguns processos antes de se tornar algum valor para a saída dessa rede. Mas o que eu quero dizer com isso? Bom, estamos criando um modelo de aprendizado de máquina, então iremos fornecer alguns dados, valores, entradas para que a máquina encontre padrões e nos retorne outros valores, certo? Então, esses valores de saída, antes mesmo de se tornarem os valores finais dessa rede, eles passam por alguns processos, equações, etc, mas onde esses processos e equações são feitos, dentro de outro neurônio:



Ou seja, cada linha dos pesos representam a quantidade dos próximos neurônios, para cada peso, um neurônio. Cada entrada em qualquer neurônio de qualquer camada irá ter a quantidade de pesos igual a quantidade de neurônios que irão recebê-la.



## Batches

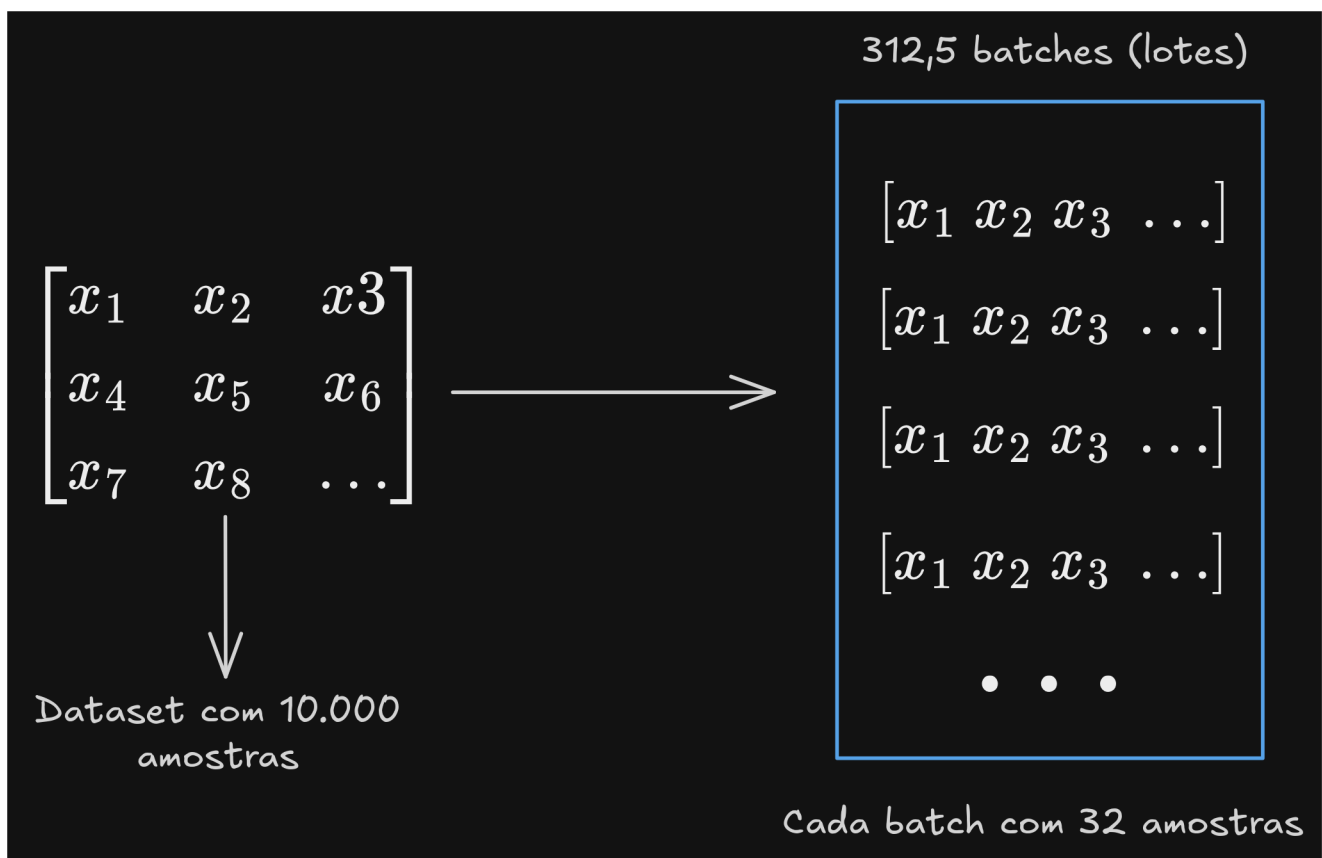
**Batches** (ou **lotes**, em português) são um conceito fundamental no treinamento de modelos de machine learning, especialmente em redes neurais. Eles se referem à divisão do conjunto de dados em pequenos grupos (lotes) que são processados separadamente durante o treinamento. Vamos explorar o que são batches, por que são usados e como funcionam.

- Um **batch** é um subconjunto dos dados de treinamento.
- Em vez de processar todos os dados de uma vez (o que é chamado de **treinamento em lote completo** ou *batch training*), os dados são divididos em lotes menores.

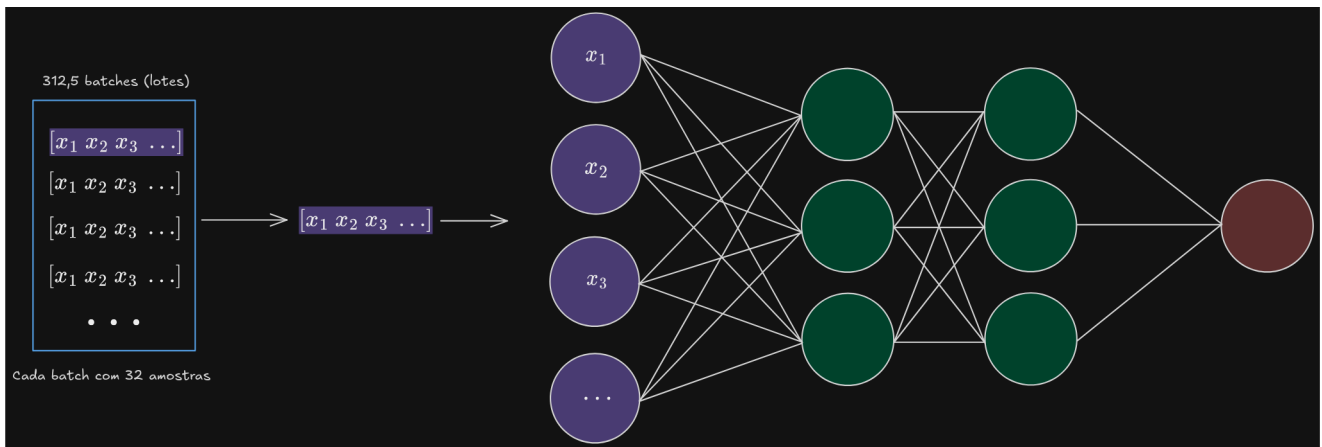
- Cada batch é passado pelo modelo para calcular o erro (ou perda) e atualizar os parâmetros do modelo.

## Exemplo:

Vamos supor que tenhamos um dataset com 10.000 features (dados de entrada, amostras, etc), para que nosso modelo não treine as 10.000 amostras de uma só vez o que poderia causar overfitting e alto custo de hardware, nós separamos essas amostras em lotes menores, ou, batches:



Depois de realizar o processo de separação de amostras, cada batch desse conjunto será utilizado para treinar o modelo e atualizar os valores, ou seja, cada batch é passado pela rede neural para calcular as predições, depois, compara-se as predições com os valores reais para computar uma função de perda (loss), então, o erro é propagado de volta pela rede para calcular os gradientes dos pesos, por fim, os parâmetros da rede (pesos e biases) são ajustados utilizando os gradientes, geralmente com algum algoritmo de otimização como SGD, Adam, etc.



Esse processo é repetido para cada batch dentro de uma época (um ciclo completo por todo o conjunto de dados). Após completar uma época, o conjunto de dados pode ser embaralhado e o processo recomeça para a próxima época até que o modelo atinja a performance desejada.

Portanto, os batches são utilizados para treinar o modelo em partes, passando cada um deles pela rede neural para calcular o erro e ajustar os pesos conforme necessário, repetindo esse ciclo durante o treinamento.

Utilizar batches durante o treinamento ajuda o modelo a identificar e aprender os padrões subjacentes nos dados, em vez de simplesmente memorizá-los. Essa abordagem favorece a generalização, permitindo que o modelo compreenda os dados de forma mais robusta e seja mais eficaz ao lidar com exemplos novos e variados.

## Código

```
import numpy as np

# Batch size: 3
# Entradas por batch: 4

inputs = [[1, 2, 3, 2.5], # Amostra 1
          [2.0, 5.0, -1.0, 2.0], # Amostra 2
          [-1.5, 2.7, 3.3, -0.8]] # Amostra 3

weights = [[0.2, 0.8, -0.5, 1.0],
           [0.5, -0.91, 0.26, -0.5],
           [-0.26, -0.27, 0.17, 0.87]]

biases = [2, 3, 0.5]

output = np.dot(inputs, np.array(weights).T) + biases
```

## Objetos

```
import numpy as np

np.random.seed(0)

# Targets (X)
X = [[1, 2, 3, 2.5],
      [2.0, 5.0, -1.0, 2.0],
      [-1.5, 2.7, 3.3, -0.8]]


class Layer_Dense:
    # Método construtor
    def __init__(self, n_inputs, n_neurons):
        self.weight = 0.10 * np.random.randn(n_inputs, n_neurons)
        self.biases = np.zeros((1, n_neurons))
```

## Explicação

`np.random.seed(0)` -> Define a semente de geração dos números, isso permite que os números sejam reproduzidos posteriormente.

`self.weight = 0.10 * np.random.randn(n_inputs, n_neurons)` -> Basicamente o que essa linha faz é criar uma variável para armazenar os pesos que serão gerados a partir da função `np.random.randn` que basicamente gera números aleatórios seguindo a distribuição normal padrão com média de 0 e desvio padrão de 1.

Distribuição Normal Padrão (`np.random.randn`)



## O que isso significa?

- A maioria dos valores gerados estará **próxima de 0**.
- Mas **não há limites fixos**: os números podem ser **negativos ou positivos**, indo de  $-\infty$  a  $+\infty$ .
- No entanto, **68% dos valores** estarão no intervalo  $-1, 1$   $[-1,1]$  (1 desvio padrão da média).
- **95% dos valores** estarão no intervalo  $-2,2$   $[-2,2]$ .
- **99.7% dos valores** estarão no intervalo  $-3,3$   $[-3,3]$ .

A multiplicação por `0.10` serve para **reduzir a escala** dos valores gerados por `np.random.randn(n_inputs, n_neurons)`.

`self.biases = np.zeros((1, n_neurons))` -> Aqui basicamente, estamos criando um vetor preenchido de zeros de acordo com a quantidade de neurônios, ou seja, inicialmente, cada neurônio irá receber um viés de 0.

Agora iremos criar nossa `forward method`, basicamente o método do nosso objeto que irá inicializar as entradas, fazer a operação de um neurônio, etc:

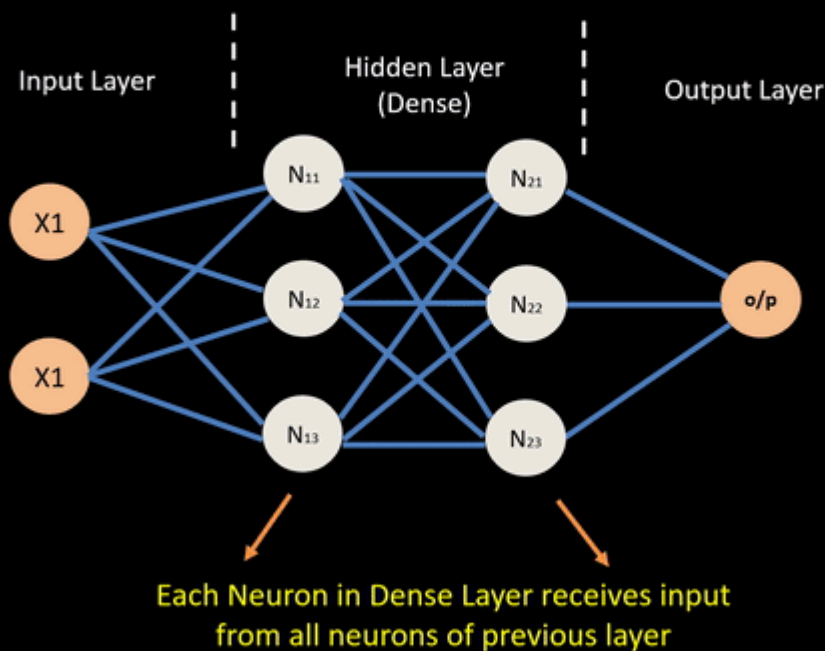
```
def forward(self, inputs):  
    self.output = np.dot(inputs, self.weights) + self.biases
```

Esse código pode ser interpretado aritmeticamente por essa fórmula:

$$\sum_{i=1}^n (x_i * w_i) + b$$

Ou seja, ela processa a saída de uma camada densa.

# Dense Layer in Deep Neural Network



© machinelearningknowledge.ai

Em uma rede neural simples, pode-se ter uma **camada de entrada** (onde os dados entram), uma ou mais **camadas densas ocultas** (onde o aprendizado ocorre) e uma **camada de saída** (onde a previsão é gerada). A camada densa é frequentemente usada nas camadas ocultas e de saída, pois sua estrutura totalmente conectada permite que a rede aprenda uma ampla variedade de padrões e complexidades.

Por exemplo, em uma rede neural para classificação, a camada densa pode ser responsável por aprender representações complexas dos dados de entrada, como uma imagem ou uma sequência de texto, para que a rede possa fazer previsões precisas sobre essas entradas.

## Código final:

```
import numpy as np

np.random.seed(0)

# Dados de entrada X
X = [[1, 2, 3, 2.5],
      [2.0, 5.0, -1.0, 2.0],
      [-1.5, 2.7, 3.3, -0.8]]

class Layer_Dense:
    def __init__(self, n_inputs, n_neurons):
```

```
self.weight = 0.10 * np.random.randn(n_inputs, n_neurons)
self.biases = np.zeros((1, n_neurons))

# Calcula a saída da camada
def forward(self, inputs):
    self.output = np.dot(inputs, self.weight) + self.biases

# Definindo a estrutura da rede
Layer1 = Layer_Dense(4, 5) # 4 entradas para 5 neurônios
Layer2 = Layer_Dense(5, 2) # 5 entradas para 2 neurônios

Layer1.forward(X) # inicializa a camada 1 com os valores de X
Layer2.forward(Layer1.output) # inicializa a camada 2 com os valores de
saída da camada 1


print(Layer2.output) # Imprime no terminal os valores de saída da camada 2
```

---


## Camada densa; Camada oculta e Camadas esparsas

Uma camada densa é um tipo de camada onde cada neurônio está conectado à todos os outros neurônios da camada anterior.






Já a camada oculta refere-se à todos os neurônios que estão entre a camada de entrada e saída da rede neural.



Um **neurônio** não precisa, necessariamente, estar conectado a todos os neurônios da camada anterior ou da camada posterior. Em uma **camada esparsa** (ou **sparse layer**), a maioria das conexões entre os neurônios é removida ou restringida, de modo que apenas algumas conexões específicas são mantidas. Ou seja, uma camada esparsa, é justamente o contrário de uma camada densa (dense layer).



---

## Função de ativação

Uma função de ativação é uma função matemática usada em redes neurais para introduzir não linearidade às saídas de cada neurônio. Ela determina se o neurônio deve ou não ser ativado em base a soma ponderada das entradas. Cada neurônio da camada oculta irá ter, individualmente sua função de ativação acoplada.